웹 크롤링이란?

- 웹 크롤링(Crawling)은 웹 페이지에서 보이는 데이터를 필요한 부분만 선택하여 수집하는 행위를 말합니다. 스크레이핑(Scraping)이라고도 합니다. 웹 크롤링에 사용되는 프로그램을 크롤러라고 합니다.
- IE, 크롬과 같은 웹 브라우저 상에서 보이는 데이터는 크롤링이 가능하다고 할 수 있습니다. 그러므로 필요로 하는 데이터를 포함하고 있는 웹 사이트를 발견하는 것이 웹 크롤링의 시작이 됩니다.
- 웹 크롤링 방법은 웹 페이지에 따라 서로 다르게 적용해야 합니다. 본 강의를 통해 웹 크롤링에 필요한 다양한 방법을 익힐 수 있습니다.

웹 크롤링 프로세스의 이해 및 주의사항

우리가 인터넷에서 정보를 검색하는 방법

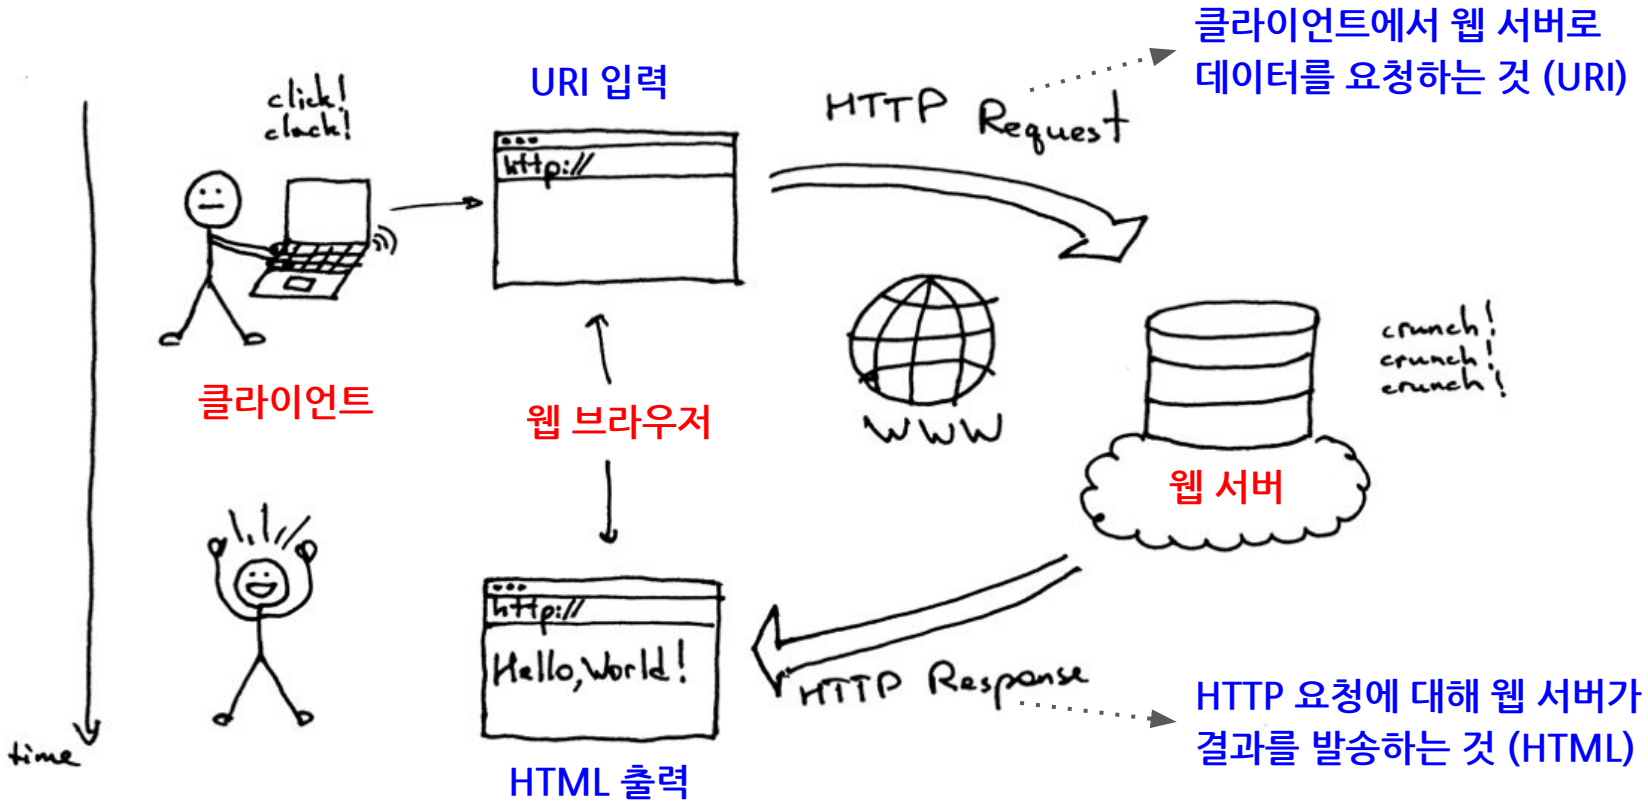

웹 크롤링은 인터넷 검색과 유사

- GET 방식과 POST 방식의 HTTP 통신
- JavaScript 및 RSelenium 이용

- 응답 결과 확인 (상태코드, 인코딩 방식 등)
- 응답 받은 객체를 텍스트로 출력
- 응답 받은 객체에 찾는 HTML 포함 여부 확인

- 응답 받은 객체를 HTML으로 변환
- CSS 또는 XPath로 HTML 요소 찾기
- HTML 요소로부터 데이터 추출

- 텍스트 전처리 (결합, 분리, 추출, 대체)
- 다양한 형태로 저장 (RDS, Rdata, xlsx, csv 등)

httr
urltools
RSelenium

rvest
jsonlite

stringr
dplyr

추가로 알아야 할 사항

크롬 개발자도구

인코딩 및 로케일

다양한 에러 해결법

정규표현식 (Regex)

웹 크롤링 관련 주의사항

- 웹 페이지는 회사가 비즈니스를 영위할 목적으로 만든 것입니다.
- 웹 크롤링은 '영업권 및 지적재산권'을 침해하는 행위로 **민사소송**에 휘말릴 수 있습니다. (잡코리아, 사람인에 승소)
    - 관련 뉴스 : http://it.chosun.com/site/data/html_dir/2017/09/27/2017092785016.html
- 따라서 웹 크롤링 하려는 웹 사이트의 메인 페이지에서 사전에 **'robots.txt'를 확인**해야 하며, 특히 수집한 데이터를 영업에 사용할 목적이라면 **반드시 법률 검토를 진행**하시기 바랍니다.

HTTP 기초

HTTP 요청(Request) 및 응답(Response)

HTTP (HyperText Transfer Protocol)

- HTTP는 '초본문 전송 규약'이라고 번역할 수 있는데, 인터넷(world wide web) 상에서 데이터를 주고 받을 때 사용되며, 주로 HTML을 주고 받습니다.
- 데이터를 주고 받는 당사자는 **'클라이언트(Client)'**와 **'웹서버(Web Server)'**입니다.
- 클라이언트가 웹서버에 데이터를 **요청(Request)**하고, 웹서버는 해당 요청에 대한 결과를 **응답(Response)**합니다.
- 클라이언트가 요청할 때 사용할 수 있는 방식(Method)에는 여러 가지가 있으며, 가장 많이 사용되는 것이 **GET 방식**과 **POST 방식**입니다.

HTTP 요청 (Request)

- 클라이언트가 웹서버에 HTTP 요청을 할 때, 웹서버에 제공해야 하는 **'요청메시지'**는 방식에 따라 다릅니다.
- GET 방식은 **'요청 라인'**과 **'요청 헤더'**를 보내야 하고, POST 방식은 위 2가지에 **'메시지 바디'**를 추가해야 합니다.

요청 라인	- 요청 방식 (GET or POST) - **경로 (URI)** - HTTP 버전 등
요청 헤더	- 가능한 콘텐츠 형식 (Content-Type) - 가능한 인코딩 방식 (Character set) - 인증 스펙 (Authorization) - Cookies - **User-agent** - **Referer** 등
메시지 바디	- URI에 포함된 파라미터들을 할당 (길이 제한 없음)

GET 방식과 POST 방식에 대한 이해

- 영어사전에서 'GET'으로 찾아보면 기본적으로 '받다, 가져오다' 등의 의미를 갖습니다.
- 웹 브라우저의 주소창에서 보이는 URI만 가지고 웹 서버에 요청할 수 있는 간단한 방법입니다.

- 영어사전에서 'POST'로 찾아보면 동사로는 '붙이다, 게시하다' 등의 의미를 갖습니다.
- 웹 브라우저의 주소창에서 보이는 URI로는 원하는 결과를 얻을 수 없으며, 크롬 개발자도구에서 관련 URL과 Parameters를 찾아야 하는 다소 복잡한 방법입니다.

URL vs URI

- URI는 **Uniform Resource Indicator**의 머리글자, 리소스를 식별하는 문자열들을 차례대로 배열한 것입니다.
- URL은 **Uniform Resource Locator**의 머리글자, 리소스가 포함되어 있는 위치를 의미합니다. URL은 URI의 부분집합이라고 생각하면 됩니다.
- [예시] 네이버 블로그 메인화면 주소(URI) : URL과 Query String의 조합

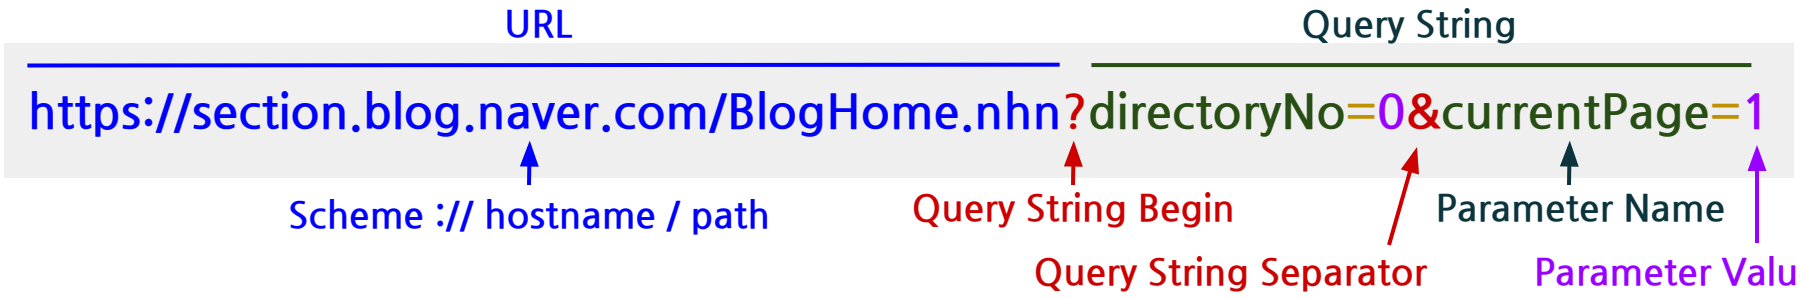

HTTP 응답 (Response)

- 웹 서버는 클라이언트의 요청에 대해 **'응답메시지'**를 발송합니다.
- 응답메시지에는 **'응답 헤더'**와 **'바디'**로 구성되어 있습니다.
- 응답 헤더는 HTTP 버전, **상태코드**, 일시, **콘텐츠 형태**, **인코딩 방식**, 크기 등이 포함되며, 바디에는 **HTML**이 포함됩니다.

상태코드	내용
1XX	정보 교환
2XX	데이터 전송 성공 or 수락됨
3XX	방향 바꿈
4XX	클라이언트 오류 (주소 오류, 권한 없음, 접근 금지 등)
5XX	서버 오류 (올바른 요청을 처리할 수 없음 등)

HTML 기초

HTML 요소(Element)의 구조

HTML (HyperText Markup Language)

- HTML은 웹 페이지의 제목, 단락, 목록 등 **문서의 구조를 나타내는 마크업 언어**입니다.
- HTML은 꺽쇠 괄호 '< >' 안에 태그로 되어 있는 HTML 요소 형태로 작성됩니다.
- HTML의 디자인을 담당하는 CSS와 웹 브라우저를 제어하는 JavaScript를 함께 사용함으로써 상호작용하는 웹 페이지를 구현할 수 있습니다.

HTML element (요소)

- HTML 요소는 HTML 문서나 웹 페이지를 구성하는 개별 항목을 의미합니다.
- HTML 요소는 시작 태그와 종료 태그로 작성되며, 그 사이에 내용이 포함됩니다.
- 태그는 꺽쇠 괄호로 감쌉니다. 시작태그에 속성명과 속성값이 포함되고, 종료 태그에는 '/'가 추가됩니다.
- 웹 크롤링은 수집하려는 부분을 포함하는 HTML 요소를 찾는 것이 필수입니다.

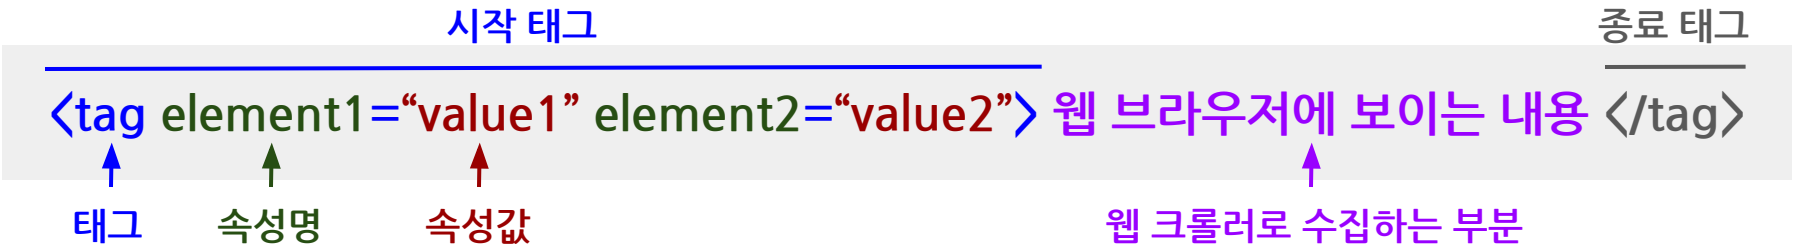

다양한 인코딩 방식의 이해

한글 인코딩이란?

- 한글 인코딩은 **'한글을 컴퓨터에 표시하는 방식'**을 말합니다.
  - 사람들이 사용하는 문자(자연어)를 컴퓨터는 읽을 수 없습니다. 대신에 0과 1로 된 2진수를 사용하였고, 2진수는 자리수를 많이 차지하므로 나중에 8진수, 16진수 등으로 발전했습니다.
  - 반대로 사람은 16진수로 된 문자를 제대로 읽을 수 없습니다. 따라서 **사람들의 문자를 컴퓨터가 이해할 수 있도록 16진수로 표기한 것이 한글 인코딩**입니다.
- 한글 인코딩에 주로 사용되는 방식은 크게 **'EUC-KR'**과 **'UTF-8'**이 있습니다.

사람이 이해하는 문자	한글 인코딩 방식	컴퓨터가 이해하는 코드
가	EUC-KR	B0A1
	UTF-8	U+AC00

한글 인코딩 방식 관계도

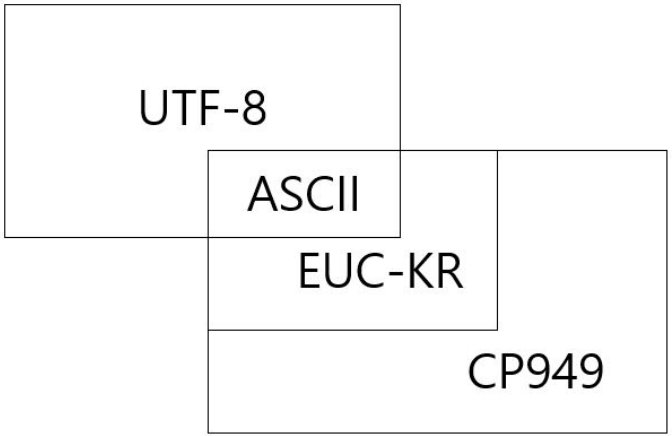

구분	설명
ASCII	● 미국에서 개발된 대표적인 영문 인코딩 방식 ● 알파벳, 숫자, 기호 등 128개가 지정되어 있음
UTF-8	● 유니코드에 기반한 인코딩 방식 (가변 길이) ● **한글 완성형과 조합형이 모두 포함 (국제 표준)**
Unicode	● 전 세계 모든 문자를 포함하는 표준 문자 방식 ● UTF-8, UTF-16, UTF-32 인코딩 방식 있음
EUC-KR	● 한글 초기 완성형 인코딩 방식 (2350자) ● 조합형은 다른 문자 체계와 호환이 되지 않음
CP949	● MS가 8822자를 추가한 통합 완성형 인코딩 방식 ● **Windows 점유율이 높은 한국에서 '사실상 표준'**

컴퓨터 운영체제별 한글 인코딩 방식

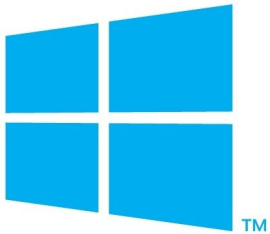

EUC-KR
(CP949)

B0A1

Decoding

Encoding

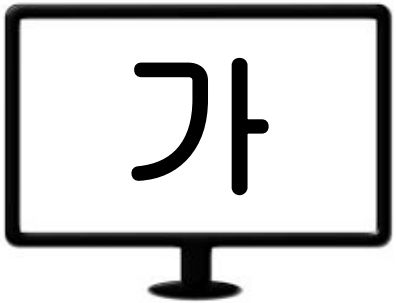

운영체제

기본 한글
인코딩 방식

문자코드

UTF-8

U+AC00

화면에 보이는 문자

한글 인코딩 방식 지정 필요성 (외부 데이터)

인코딩 방식 지정 구분 (O : 필요함, X : 필요 없음)		컴퓨터 운영체제별 한글 인코딩 방식	
		Windows (CP949)	Mac (UTF-8)
HTML의 인코딩 방식	EUC-KR (CP949)	X	O
	UTF-8	O	X
	기타	O	O

로케일(Locale)이란?

- 국가마다 서로 다른 문화를 가지고 있다 보니, 시간을 표시하는 방법이라든가 숫자를 표시하는 방법 등에서 상당한 차이를 보입니다. 따라서 운영체제(OS)는 국가마다 서로 다른 로케일을 제공하고 있습니다.
- 로케일은 국가마다 다음과 같은 여러 가지 표시 형식을 설정하는 것입니다.
    - LC_COLLATE(문자 정렬), LC_CTYPE(문자 처리), LC_MONETARY(통화), LC_NUMERIC(숫자), LC_TIME(날짜/시간), LC_MESSAGES(언어/문화) 등

로케일을 왜 알아야 하나?

- 한글 인코딩 방식이 로케일에 영향을 받기 때문입니다.
- 아울러 EUC-KR 또는 CP949 인코딩 방식의 R 객체를 처리하지 못하는 함수가 있습니다. html_table() 함수가 한 예입니다.

[참고] 국가별 로케일 이름 (locale 인자에 추가하는 이름)

로케일	Windows		Mac	
	로케일 이름	인코딩 방식	로케일 이름	인코딩 방식
대한민국	korean	CP949	ko_KR	UTF-8
미국	english	ISO8859-1	en_US	UTF-8
중국	chinese	CP936	zh_CN	UTF-8
일본	japanese	CP932	ja_JP	UTF-8
기본값	C	ASCII	C	ASCII

퍼센트 인코딩이란?

- 퍼센트 인코딩(percent-encoding)이란 URL에 사용되는 문자를 인코딩하는 방식이며 URL 인코딩이라고도 합니다. 아울러 한글 인코딩 방식에 따라 결과가 달라집니다. 예를 들어 '웹크롤링'을 퍼센트 인코딩한 결과는 다음과 같습니다.

UTF-8	%EC%9B%B9%ED%81%AC%EB%A1%A4%EB%A7%81
EUC-KR	%C0%A5%C5%A9%B7%D1%B8%B5

- 네이버 메인에서 웹크롤링으로 검색한 다음, 변경된 url를 복사하여 텍스트로 붙여넣기 해보시면 query 파라미터에 할당된 값이 아래와 같이 바뀝니다.
  - https://search.naver.com/search.naver?sm=top_hty&fbm=1&ie=utf8&query=%EC%9B%B9%ED%81%AC%EB%A1%A4%EB%A7%81

크롬 개발자도구 사용법

Elements 탭에서 HTML 요소 찾는 방법

크롬 개발자도구를 사용하는 이유

- ‘크롬 개발자도구’는 웹 페이지에서 수집하려는 내용을 담고 있는 HTML 요소를 찾거나, HTTP 요청 과정에서 클라이언트와 웹 서버 간 주고 받은 (사용자에게 보이지 않는) 리소스를 찾고자 할 때 사용합니다.
- 크롬 메뉴에서 **‘도구 더보기(More Tools) -> 개발자도구(Developer Tools)’**를 선택하면 됩니다.
- 크롬 개발자도구에서 제공되는 탭은 Elements 외 8개이지만, 이번 강의에서는 **Elements**와 **Network**만 사용합니다.

HTML 요소 찾기 (첫 번째 방법)

- 크롬 브라우저에서 웹 사이트로 이동한 다음, 수집하려는 내용 위에서 **마우스 오른쪽 버튼을 클릭**하면 메뉴가 뜹니다.
- **'검사(Inspect)' 메뉴를 선택**하면 크롬 개발자도구가 열리며 **해당 HTML 요소가 파란색으로 표시**됩니다.

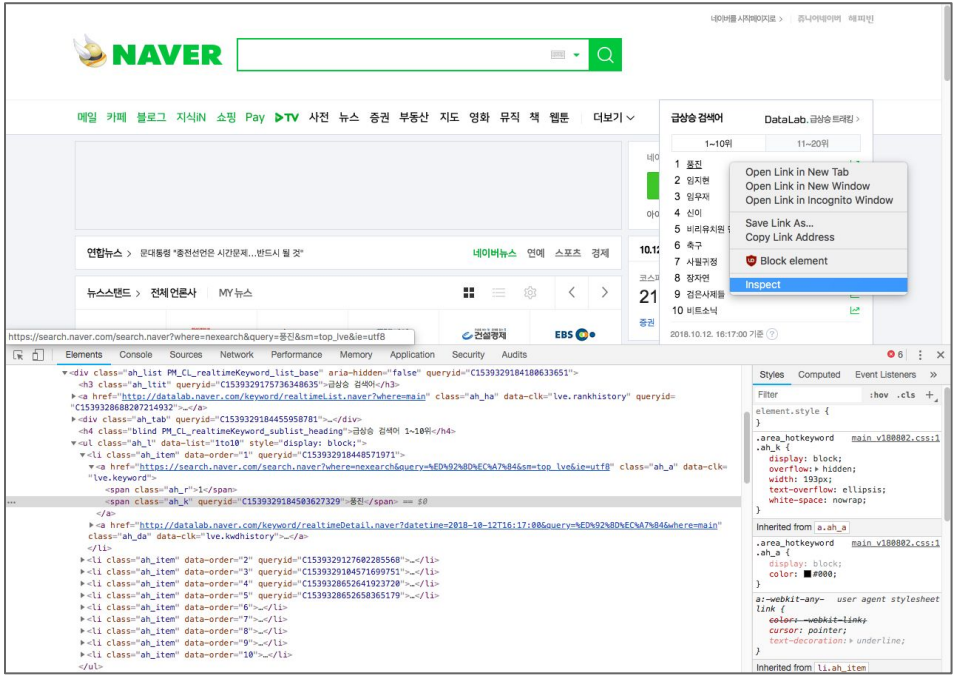

HTML 요소 찾기 (두 번째 방법)

- 크롬 개발자도구 화면에서 (아래 빨간 점선으로 표시된) 버튼을 한 번 클릭한 다음 웹 페이지에서 원하는 정보를 선택하면, Elements 탭에서 해당 HTML 요소가 파란색으로 표시됩니다.

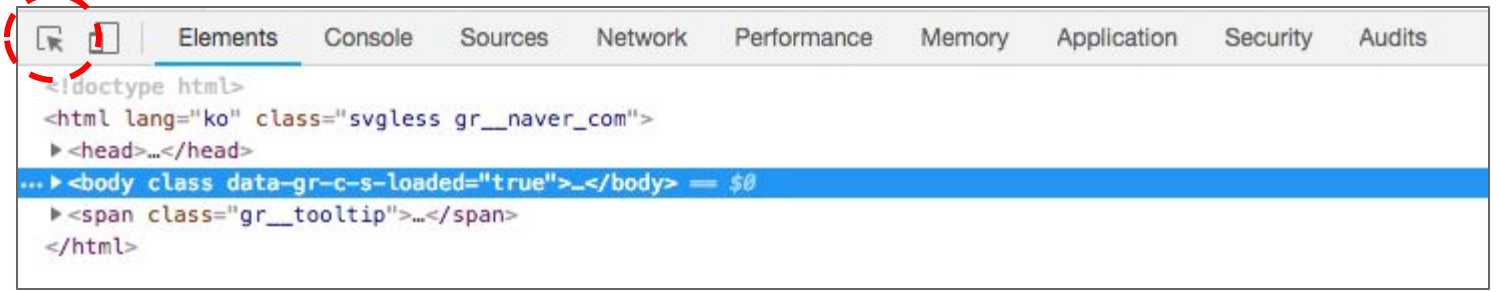

HTML 요소 지정 : CSS Select 또는 XPath

- HTML 요소 위에 마우스 오른쪽 버튼을 클릭한 다음 **'Copy'**를 선택하면 하위 메뉴 창이 열립니다. 이 때, **'Copy selector'** 또는 **'Copy XPath'**를 선택하면 됩니다.

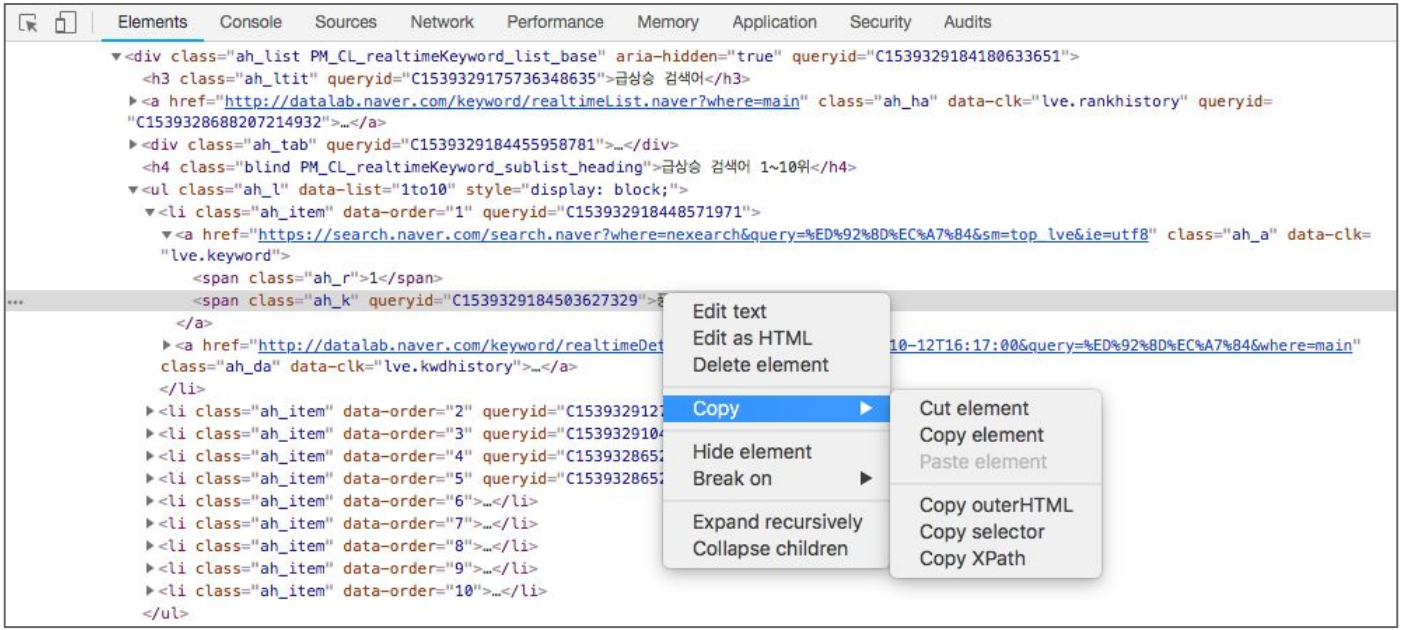

네이버 실시간 검색어 1위 HTML 요소의 CSS와 Xpath 비교

- **CSS Selector**

  #PM_ID_ct > div.header > div.section_navbar >
  div.area_hotkeyword.PM_CL_realtimeKeyword_base >
  div.ah_list.PM_CL_realtimeKeyword_list_base > ul:nth-child(5) >
  li:nth-child(1) > a.ah_a > span.ah_k

- **Xpath**

  //*[@id="PM_ID_ct"]/div[1]/div[2]/div[2]/div[2]/ul[1]/li[1]/a[1]/span[2]

CSS Selector과 XPath 비교

- **CSS는 HTML의 디자인을 담당**합니다. HTML 요소에 포함된 Selector를 참조하여 웹 브라우저에 출력되는 모습을 변경합니다. (폰트, 컬러, 크기, 굵기 등)
- **XPath는 XML Path Language**를 나타내며, 계층 구조를 갖는 XML 문서에서 노드(HTML의 태그)를 탐색하는 경로로 사용됩니다.
- 이 두 가지는 HTML 요소를 지정할 때 (우열 없이) 사용됩니다. 다만 XPath의 경우 Selenium에서 사용될 경우 좀 더 빠르다는 의견이 있습니다. 이번 강의에서는 일반적인 크롤러에서는 CSS Selector를 사용하고, RSelenium에서는 XPath를 사용하여 HTML 요소를 지정하도록 하겠습니다.

CSS Selector와 XPath 표기법 [매우 중요!]

CSS Selector		XPath	
표현식	의미	표현식	의미
태그명	태그명이 같은 모든 태그를 선택	노드명	노드명이 같은 모든 노드를 선택
>	앞 태그의 직계 자손 태그에서 선택	/	루트노드부터 탐색. 부모노드/자식노드 경로
#	속성명이 'id'인 태그를 선택	//	위치와 상관없이 지정된 노드부터 탐색
.	속성명이 'class'인 태그를 선택	.	현재노드 선택 ('..'는 부모노드 선택)
[ ]	속성을 지정할 때 사용	@	속성노드 선택
:nth-child	n번째 태그를 선택할 때 사용	[ ]	속성 지정 및 n번째 노트를 선택할 때 사용

CSS Selector와 XPath 표기법 [매우 중요!]

목표	CSS Selector	XPath
모든 요소	*	//*
p 태그를 포함하는 모든 요소	p	//p
p 태그의 모든 자식 요소	p > *	//p/*
id가 'foo'인 모든 요소	#foo	//*[@id='foo']
class가 'foo'인 모든 요소	.foo	//*[@class='foo']
title='header' 속성을 포함하는 모든 요소	*[title='header']	//*[@title='header']
li 태그 중 n번째인 요소	li:nth-child(n)	//li[n]
ul 자식 태그인 li 태그 중 n번째인 요소	ul > li:nth-child(n)	//ul/li[n]

관련 R 패키지 및 주요 함수 소개

웹 크롤링 관련 R 패키지 목록

- HTTP 통신 : **httr**, RSelenium
- HTML 요소 : **rvest**, jsonlite
- 인코딩 관련 : **urltools**, readr
- 파이프 연산자 : magrittr (**dplyr**)
- 텍스트 전처리 : **stringr**
    - tidyverse 패키지를 불러오면 8개의 패키지를 한 번에 불러올 수 있는데 그 중에 readr, dplyr 및 stringr 패키지가 포함되어 있습니다.

HTTP 통신 관련 : httr 패키지 소개

- httr은 HTTP 요청 및 응답에 관한 작업에 사용되는 패키지입니다.
- 주요 함수는 다음과 같습니다.
  - HTTP 요청에 관한 함수들 : **GET**(), **POST**(), user_agent(), add_headers(), set_cookies()
  - HTTP 응답에 관한 함수들 : **status_code**(), **content**(), cookies(), headers()
  - HTTP 응답에 성공하지 못했을 때 사용하는 함수들 : warn_for_status(), stop_for_status()

httr 패키지 주요 함수 1 : GET 방식의 HTTP 요청

- res <- **GET**(url = '요청할 웹 페이지 URL',

  query = list(a = 'a에 할당된 값',

  b = 'b에 할당된 값'),

  …)

  - GET 방식의 HTTP 통신이 사용된 경우, GET() 함수를 사용합니다.
  - url 인자에 웹 페이지의 URL 부분을 할당하고,
  - query 인자에 query string을 **list** 형태로 할당합니다.

httr 패키지 주요 함수 2 : POST 방식의 HTTP 요청

- res <- **POST**(url = '요청할 웹 페이지 URL',

  body = list('POST 방식 요청에 사용될 파라미터'),

  encode = c('multipart', 'form', 'json', 'raw'))

  - POST 방식으로 HTTP 통신하는 경우에는 POST() 함수를 사용해야 합니다.
  - GET() 함수와 달리 POST() 함수는 query 인자 대신 body와 encode 인자를 추가합니다.
  - body와 encode 인자에 지정하는 값은 크롬 개발자도구의 네트워크 탭에서 찾습니다.
  - encode의 경우, 4가지 중 해당하는 한 가지를 선택하거나 생략할 수 있습니다.

httr 패키지 주요 함수 3 : 상태코드 및 응답 결과 확인

- **print**(x = res)
  - HTTP 응답 결과를 한 번에 출력합니다.
- **status_code**(x = res)
  - HTTP 응답 상태코드만 출력합니다. 사용자 정의 함수 등에서 유용하게 사용할 수 있습니다.
- **content**(x = res, as = 'text', type = 'text/html', encoding = 'EUC-KR')
  - HTTP 응답 바디(HTML)를 텍스트 형태로 출력하여 육안으로 확인합니다.
  - type과 encoding 인자는 추가하지 않아도 자동으로 설정됩니다.
  - 하지만 encoding 인자는 상황에 따라 반드시 추가해야 하는 경우가 있습니다.

HTML 요소 관련 : rvest 패키지

- **rvest**는 웹 페이지로부터 데이터를 수집할 때 사용하는 패키지입니다.
- 주요 함수는 다음과 같습니다.
  - 응답 객체를 HTML로 변환하는 함수 : **read_html()**
  - HTML 요소를 추출하는 함수 : **html_node(), html_nodes()**
  - HTML 속성에 관련된 함수 : **html_attr()**, html_attrs(), html_name()
  - 데이터를 추출하는 함수 : **html_text(), html_table()**

rvest 패키지 주요 함수 1 : 응답 객체에서 HTML 읽기

- html <- **read_html**(x = res, encoding = 'UTF-8')
  - HTTP 응답 객체인 res로부터 HTML을 읽은 다음 html 객체에 할당합니다. 이 때 주의해야 할 사항은 **res 객체의 한글 인코딩 방식을 지정해주어야 한다**는 것입니다.
  - res 객체의 한글 인코딩 방식을 확인하는 방법은 print(x = res)를 실행하면 됩니다.
  - Windows 컴퓨터는 한글 인코딩 방식으로 'EUC-KR'을 사용하므로, HTTP 응답 객체의 한글 인코딩 방식이 'EUC-KR'이 아닌, 예를 들어 'UTF-8'이면 반드시 `encoding` 인자를 추가해주어야 합니다.
  - 반대로 Mac 컴퓨터는 한글 인코딩 방식으로 'UTF-8'을 사용하므로, HTTP 응답 객체의 한글 인코딩 방식이 'UTF-8'이 아닌, 예를 들어 'EUC-KR'이면 반드시 `encoding` 인자를 추가해주어야 합니다.

rvest 패키지 주요 함수 2 : HTML 요소 찾기

- item <- **html_node**(x = html,

  css = '크롬 개발자도구에서 복사해온 CSS Selector',

  xpath = '크롬 개발자도구에서 복사해온 Xpath')

  - html_node() 함수 인자 중 `css`와 `xpath` 둘 중 하나만 사용하면 됩니다.
  - html_node() 함수와 html_nodes() 함수는 사용법이 같습니다. 다른 점은 html_node() 함수는 찾고자 하는 HTML 요소가 여러 개 있을 때 맨 처음 하나만 가져오지만, html_nodes() 함수는 모든 HTML 요소를 가져옵니다. 따라서 일반적으로 html_nodes() 함수가 더 유용합니다.
  - html_node() 함수는 **찾는 HTML 요소가 없으면 NA를 반환**합니다.

rvest 패키지 주요 함수 3 : HTML에서 텍스트 추출

- text <- **html_text**(x = item, trim = FALSE)
  - HTML 요소 중 시작 태그와 종료 태그 사이에 있는 '웹 브라우저에 보이는 내용'을 수집하려고 할 때 html_text() 파일을 사용하면 됩니다.
  - html_node() 함수 또는 html_nodes() 함수로 추출한 HTML 요소에 있는 모든 텍스트를 추출합니다.
  - `trim` 인자에 FALSE가 기본값으로 설정되어 있으나, TRUE로 추가하면 문자열 양 옆의 불필요한 여백을 깔끔하게 제거할 수 있습니다.

rvest 패키지 주요 함수 4 : 표에 있는 내용 일괄 수집

- tbl <- **html_table**(x = item, fill = FALSE)
  - HTML의 'table' 태그는 웹 브라우저에서 표 형태로 데이터를 출력합니다. 테이블 안에 포함된 모든 데이터를 데이터 프레임 형태로 수집하고자 할 때 html_table() 함수를 사용합니다.
  - Mac 사용자의 경우, 이 함수를 사용할 때 전혀 문제가 발생하지 않지만 Windows 사용자는 에러가 발생합니다. 그 이유는 한글 인코딩 방식 때문입니다.
  - 이러한 에러를 우회하는 방법으로 '로케일 변경'을 시도할 수 있습니다.

파이프 연산자 관련 : magrittr 패키지

- text <- res %>%

  read_html(encoding = 'UTF-8') %>%

  html_node(css = 'CSS Selector', xpath = 'XPath') %>%

  html_text(trim = TRUE)

  - 이 강의에서는 **파이프 연산자(%>%)를 사용**합니다.
  - 파이프 연산자는 이전 함수 실행 결과를 다음 함수의 첫 번째 인자로 전달하기 때문에 코드의 흐름대로 이해할 수 있으며, 불필요한 객체를 여러 개 만들 필요가 없습니다.
  - 파이프 연산자를 사용하려면 **magrittr** 패키지를 로딩해야 합니다.

한글 인코딩 관련 : 기본 패키지 + readr 패키지

- localeToCharset() : 컴퓨터에 설정된 로케일의 문자 인코딩 방식을 확인합니다.
- iconv(x = '문자열', from = 'UTF-8', to = 'EUC-KR') : 인코딩 방식을 변경합니다.
- readr::guess_encoding(file = '파일명') : 컴퓨터에 저장된 파일 또는 URL의 문자 인코딩 방식을 확인합니다.

로케일 관련 : 기본 패키지

- Sys.getlocale() : 현재 설정된 로케일을 확인합니다.
- Sys.setlocale(category = 'LC_ALL', locale = 'locale name') : 로케일 설정을 변경합니다.
    - category 인자에는 'LC_COLLATE', 'LC_CTYPE', 'LC_MONETARY', 'LC_NUMERIC', 'LC_TIME' 등 개별 카테고리를 지정할 수 있으나 편의상 'LC_ALL'로 지정하도록 합니다.
    - locale 인자에 지정할 locale name은 운영체제에 따라 서로 다릅니다.
    - Sys.setlocale() 함수 안에 아무런 인자를 지정하지 않으면 운영체제의 기본값으로 설정됩니다.

퍼센트 인코딩 관련 : urltools 패키지

- 퍼센트 인코딩된 문자열은 **urltools** 패키지를 이용합니다.
  - **url_decode**(urls = '문자열A') : 문자열A를 퍼센트 디코딩하여 사람이 읽을 수 있도록 합니다.
  - **url_encode**(urls = '문자열B') : 문자열B를 퍼센트 인코딩하여 컴퓨터가 읽을 수 있도록 합니다.

텍스트 전처리 관련 : stringr 패키지

- stringr 패키지는 문자 데이터를 다루는 데 필요한 주요 함수를 담고 있습니다.
- R 기본 함수로도 충분히 가능하지만, 문제는 파이프 연산자를 사용할 수 없는 경우가 있다는 것입니다. 따라서 이번 강의에서는 stringr 패키지를 사용합니다.
- stringr 패키지의 주요 함수로는 다음과 같은 작업을 할 수 있습니다.
    - 패턴을 포함하고 있는지 확인 (str_detect)
    - 패턴을 삭제(str_remove)하거나 교체(replace) 또는 추출(extract) 및 인덱스로 자르기(sub)
    - 문자열을 하나로 묶음(str_c) 또는 분리(str_split)
    - 문자열의 양 옆에 있는 공백 제거(str_trim)

stringr 패키지 주요 함수 1 : 패턴 포함 여부 확인

- 문자열을 담고 있는 객체에서 찾고자 하는 패턴이 포함되어 있는지 확인할 수 있습니다.

  > string <- '동해물과 백두산이 마르고 닳도록 하느님이 보우하사 우리나라 만세'

  > string %>% **str_detect**(pattern = '우리나라')
  ## [1] TRUE

  > string %>% **str_detect**(pattern = '하나님')
  ## [1] FALSE

stringr 패키지 주요 함수 2 : 패턴을 한 번 또는 모두 삭제

- 문자열에서 맨 처음 나오는 패턴을 한 번 삭제할 수 있습니다.

  > string %>% **str_remove**(pattern = ' ')

  ## [1] '동해물과백두산이 마르고 닳도록 하느님이 보우하사 만세'

- 지정한 패턴이 여러 번 나오는 경우, 모두 삭제할 수 있습니다.

  > string %>% **str_remove_all**(pattern = ' ')

  ## [1] '동해물과백두산이마르고닳도록하느님이보우하사우리나라만세'

stringr 패키지 주요 함수 3 : 패턴을 한 번 또는 모두 교체

- 문자열에서 맨 처음 나오는 패턴을 한 번 교체할 수 있습니다.

  ```
  > string %>% str_replace(pattern = ' ', replacement = '_')
  ## [1] '동해물과_백두산이 마르고 닳도록 하느님이 보우하사 우리나라 만세'
  ```

- 지정한 패턴이 여러 번 나오는 경우, 모두 교체할 수 있습니다.

  ```
  > string %>% str_replace_all(pattern = ' ', replacement = '_')
  ## [1] '동해물과_백두산이_마르고_닳도록_하느님이_보우하사_우리나라_만세'
  ```

stringr 패키지 주요 함수 4 : 패턴을 한 번 또는 모두 추출

- 문자열에서 맨 처음 나오는 패턴을 한 번 추출할 수 있습니다.

  ```
  > string %>% str_extract(pattern = '우')
  ## [1] '우'
  ```

- 지정한 패턴이 여러 번일 때 모두 추출할 수 있습니다. 단, 결과는 리스트입니다. 함수 안에 **'simplify = TRUE'**를 추가하면 리스트 대신 행렬로 출력됩니다.

  ```
  > string %>% str_extract_all(pattern = '우')
  ## [[1]]
  ## [1] '우' '우'
  ```

stringr 패키지 주요 함수 5 : 문자열을 인덱스로 자르기

- 문자열의 인덱스를 이용하여 필요한 부분만 자를 수 있습니다.

```
> string %>% str_sub(start = 1, end = 2)
## [1] 동해

> string %>% str_sub(start = 3, end = 4)
## [1] 물과

> string %>% str_sub(start = 6, end = 7)
## [1] 백두
```

stringr 패키지 주요 함수 6 : 문자열을 하나로 묶음

- 두 개 이상의 문자열을 하나의 커다란 문자열로 묶을 수 있습니다.

```
> str_c('우리나라', '만세')
## [1] 우리나라만세

> str_c('우리나라', '만세', sep = ' ')
## [1] 우리나라 만세
```

stringr 패키지 주요 함수 7 : 문자열을 구분자로 분리

- 하나의 문자열을 구분자 기준으로 여러 개의 문자열로 분리할 수 있습니다.
  단, 리스트 객체로 결과가 반환됩니다.

  ```
  > string %>% str_split(pattern = ' ')
  ## [[1]]
  ## [1] '동해물과' '백두산이' '마르고' '닳도록' '하느님이' '보우하사' '우리나라' '만세'
  ```

stringr 패키지 주요 함수 8 : 양 옆의 공백 제거

- 문자열 양 옆에 있는 불필요한 공백을 제거할 수 있습니다.

```
> string <- '\r\n\t\t\t\t  하느님이 보우하사  \r\n\t\t\t\t'
> string %>% str_trim()
## [1] 하느님이 보우하사
```